

Intitulé de l'examen : Machine Learning avec Python : implémenter et évaluer des modèles d'apprentissages automatiques.

Type d'examen : ☒ Examen blanc ☐ Examen officiel

Condition de déroulement de l'examen :

- Date : fixée par l'organisme formateur
- Heure : fixée par l'organisme formateur
- Lieu : fixé par l'organisme formateur
- Matériel autorisé : ordinateur, connexion internet
- Durée maximale de l'examen : 02h00
- Conditions de travail :
 - Durant toute la durée de l'examen, il vous est conseillé de travailler dans un environnement calme.
 - Le candidat doit travailler de manière autonome et ne pas communiquer avec les autres candidats.

Consignes d'examen :

Tous les sujets doivent obligatoirement être traités.

L'examen est évalué à la fois sur des questions théoriques et pratiques. Il n'y a aucune question piège.

Cas d'usage 1 (niveau intermédiaire) : Prédiction des prix de l'immobilier

Contexte :

Une agence immobilière souhaite prédire les prix de vente de maisons dans une ville donnée en fonction de diverses variables (taille, nombre de chambres, localisation, etc.). L'objectif est d'aider les agents immobiliers à estimer plus précisément la valeur des propriétés pour mieux conseiller les vendeurs et les acheteurs.

Source de données :

https://raw.githubusercontent.com/JoyceMbiguidi/data/main/Boston_dataset.csv

Description des données :

Boston Housing contient des informations socio-économiques et des caractéristiques de logements à Boston dans les années 1970.

- CRIM : Taux de criminalité par habitant
- ZN : Proportion de terrains résidentiels de plus de 25 000 pieds carrés
- INDUS : Proportion de terrains industriels dans la ville
- CHAS : Variable binaire (0 ou 1) indiquant si le logement est adjacent à la rivière Charles
- NOX : Concentration d'oxydes nitriques (pollution de l'air)
- RM : Nombre moyen de pièces par logement
- AGE : Proportion de logements occupés construits avant 1940
- DIS : Distance pondérée par rapport aux principaux centres d'emploi
- RAD : Indice d'accessibilité aux autoroutes
- TAX : Taux d'imposition foncière par tranche de 10 000 dollars
- PTRATIO : Ratio élèves-enseignants par ville
- B : Calculé comme $1000(Bk - 0.63)^2$ où Bk est la proportion de résidents noirs
- LSTAT : Pourcentage de la population ayant un faible statut socio-économique
- MEDV : Valeur médiane des maisons

Objectif :

L'objectif est de construire un modèle qui pourra prédire le prix de vente d'une maison en fonction des variables disponibles.

1. Au regard du type de données et de la problématique rencontrée par l'agence immobilière, quelle est la variable cible¹ selon vous ?
2. Quelles variables peuvent potentiellement expliquer le phénomène décrit par l'agence immobilière ?
3. Quels types d'algorithmes² peuvent répondre à la problématique de l'agence immobilière ?
4. A quelle famille d'algorithme appartiennent ces algorithmes ?
5. Quelles sont les principales étapes de la préparation des données dans ce cas précis ?
6. Quels sont les critères³ de sélection du modèle qui prédira les prix de l'immobilier ?
7. Comment traiteriez-vous un cas où les données disponibles sont déséquilibrées, avec beaucoup plus de maisons de faible valeur que de maisons de grande valeur ?
8. Comment intégreriez-vous de nouvelles variables comme la proximité des écoles ou des parcs dans votre modèle existant, si elles sont de natures quantitatives ?

¹ La variable cible est également appelée Y , ou encore variable à expliquer.

² Citez au moins 2 (deux) algorithmes.

³ Métriques d'évaluation d'un modèle d'apprentissage automatique, dans le cas en l'espèce.

9. Comment intégreriez-vous de nouvelles variables comme la proximité des écoles ou des parcs dans votre modèle existant, si elles sont de natures qualitatives ?
10. Pourquoi standardiser ou normaliser les données avant de les utiliser dans un modèle ?
11. Comment feriez-vous pour déterminer le meilleur modèle d'apprentissage automatique après l'avoir comparé avec un autre ?

Cas d'usage 2 (niveau avancé) : Détection de fraude bancaire

Contexte :

Une banque souhaite améliorer son système de détection de transactions frauduleuses. L'objectif est de détecter en temps réel si une transaction donnée est frauduleuse ou non, en se basant sur l'historique des transactions précédentes.

Source de données : Aucune

Description des données : Aucune

Problème à Résoudre : Classer chaque transaction comme "illicite" ou "licite".

1. Supposons que vous disposez d'un jeu de données déséquilibré pour un projet de détection de fraude. Quelles techniques pourriez-vous utiliser pour équilibrer les classes ?
2. Quels algorithmes⁴ peuvent répondre à la problématique ?
3. A quelle famille d'algorithme appartiennent ces algorithmes ?
4. Comment évalueriez-vous la performance d'un modèle de détection de fraude ?
5. Supposons que votre modèle de classification présente un rappel élevé mais une précision faible. Quelles actions pouvez-vous entreprendre pour améliorer la précision ?
6. Comment utiliseriez-vous une recherche en grille (Grid Search) pour optimiser les hyperparamètres d'un modèle de Random Forest ?
7. Un modèle de détection de fraude a été déployé en production, mais vous remarquez une augmentation du taux de faux positifs. Quelles pourraient être les causes ?
8. Comment les résoudre ?
9. Comment vous diviseriez votre jeu de données en ensembles d'entraînement et de test ?
10. Que feriez-vous si votre modèle de détection de fraude surperforme sur les données d'entraînement mais échoue sur les données de test ?
11. Il est fréquent de comparer les performances de plusieurs modèles d'apprentissage automatique. Comment feriez-vous pour déterminer lequel est le meilleur dans le cas en l'espèce ?

⁴ Citez au moins 2 (deux) algorithmes.

Cas d'Usage 3 (niveau avancé) : Classification des Espèces d'Iris

Contexte :

Le jeu de données Iris est un jeu de données bien connu en apprentissage automatique, contenant 150 observations de trois espèces d'iris : *Iris setosa*, *Iris versicolor* et *Iris virginica*. Chaque observation inclut quatre caractéristiques mesurées en centimètres : la longueur et la largeur des sépales, ainsi que la longueur et la largeur des pétales. L'objectif est de construire un modèle de classification capable de prédire l'espèce d'iris en fonction de ces quatre caractéristiques.

Source de données : cf. lien github se trouvant dans le notebook fourni

Description des données :

Le jeu de données se compose de 150 lignes et 5 colonnes :

- sepal_length : longueur du sépale en cm.
- sepal_width : largeur du sépale en cm.
- petal_length : longueur du pétale en cm.
- petal_width : largeur du pétale en cm.
- species : espèce d'iris (trois classes : *setosa*, *versicolor*, *virginica*).

Problématique :

Vous êtes Data Scientist dans une entreprise botanique et votre mission est de créer un modèle de classification pour identifier l'espèce d'iris à partir des caractéristiques décrites ci-dessous. Ce modèle sera utilisé par les botanistes pour automatiser la classification des échantillons d'iris.

Votre stagiaire a tout développé pendant vos congés, cependant il peut y avoir des erreurs dans le code⁵ et potentiellement des erreurs de méthodologie⁶. Faites un code review et proposez une correction de son travail.

Le notebook du stagiaire est : `iris_exercice_examen_blanc.py`

Après avoir sélectionné 20% des données pour effectuer le test et fixé la graine à 42 (`random_state = 42`), quelle est la valeur de l'accuracy ?

⁵ Aucun piège. Il a simplement rencontré des erreurs dans le code qui peuvent l'empêcher de progresser sereinement. A vous de les comprendre et de trouver la solution.

⁶ Soyez concentré, restez logique et méthodique pour trouver les erreurs de méthodologie.